中文源码导读 · 2026-10-23 · 本版核查版本 v1.4.0
12 章 · 12 张架构图 · 6 个可验证脚本

从工具循环到 Code Mode

Pi 架构演进：v0.9.4、v0.99.2 与 v1.4.0

一部跟着源码读的中文电子书。 本版依据官方仓库、固定版本源码和发布记录整理，核查日期为 2026 年 10 月 23 日，比较端点更新为 v1.4.0，正式发布时间为 2026 年 10 月 21 日。保留 v1.3.0 作为上一版参照，本书不把标签之后 `main` 上的代码混进来。

先说结论：Pi 的核心仍是“模型产生响应，工具执行操作，结果供下一轮模型使用”的循环。变化主要发生在循环外围：树形会话、统一扩展系统、更丰富的工具契约、内置 MCP，以及让模型用 JavaScript 编排工具的 Code Mode。仓库另外提供独立的实验性 Durable 运行时，可以恢复中断任务，但普通 CLI 没有切换到它，它也不是新内核。

本书沿用同目录学习课程的组织方式：一章解决一个问题，先建立直觉，再看图、沿源码追踪，最后做例子和练习。重点了解 Code Mode，可以先读第 1、3、5、6、8、11 章；想理解整套架构则顺序阅读。你只需了解基本 JavaScript、Promise，以及“模型能够请求调用工具”这一概念，不需要预先掌握编译器或 WebAssembly。

目录

第 1 章：先把版本说清楚

第 2 章：v0.9.4 原本是怎样工作的

第 3 章：当前架构，分清 CLI 与独立基础库

第 4 章：一次请求的完整生命周期

第 5 章：Code Mode 到底改变了什么

第 6 章：拆开沙箱，看见真正的调用链

第 7 章：工具太多时，怎样发现而不塞满提示

第 8 章：结果、失败、并发与状态

第 9 章：扩展、模型与界面，哪些没被 Code Mode 替代

第 10 章：从 0.99.2 到 1.4.0，具体差了什么

第 11 章：独立沙箱、云端执行与 Durable 重放

第 12 章：迁移路线与动手实验

来源索引与核查范围

第 1 章：先把版本说清楚

本章目标：弄清我们比较的是哪两个版本区间。

`0.9.x` 和 `0.99.x` 不是同一组版本。版本号按整数元组比较，不是小数；次版本号 99 排在 9 之后。把两者混为一谈，就会把早已存在的能力误写成最新版本才出现。

参照点	日期及依据	为什么重要
v0.9.4	2025-11-26，标签对应提交	可用的最后一个 0.9.x 标签；传输抽象、早期工具循环、线性会话文件
v0.31.0	2026-01-02，变更日志	单文件内的树形会话与原地分支
v0.35.0	2026-01-05，变更日志	hooks 与自定义工具统一成 extensions
v0.99.0	2026-09-29，变更日志	内置 Code Mode、工具搜索、MCP 与嵌套工具契约
v0.99.2	2026-09-30，变更日志	MCP 按需发现，减少启动等待和工具描述变化
v1.0.0	2026-10-01，变更日志	更精简的 Code Mode 提示、图像生成、默认全屏 TUI
v1.3.0	2026-10-15，正式发布	上一版参照；取消与 worker 数量控制、恢复活动工具集等修复
v1.4.0	2026-10-21，正式发布	本版端点；worker 排队、摘要输出预算、图片分类及恢复边界修复

官方仓库现在叫 `earendil-works/pi`，历史上的 `badlogic/pi-mono` Git 地址仍能访问到这个项目。旧源码里的包名前缀是 `@mariozechner/*`，当前是 `@earendil-works/*`。改名是迁移时必须处理的事情，但改名本身不是一种新 Agent 算法。S1、S2

你原有的 `learning/pi-mono` 检出点显示为 `v0.54.0-1-g3a3e37d3`，而且存在本地修改。本次没有修改它，也没有升级当前安装的 Pi。`sources/` 单独保存四个用于比较的固定版本，新增 `pi-v1.4.0/`，不改动原有三个源码检出点。

本书说的“架构”包括什么

我们比较模块职责、依赖边界、数据流、状态归属、扩展方式和失败行为，不逐条复述所有模型新增和终端按键修复。完整的文件级变更清单另存于 `sources/`，需要穷尽排查时可以查阅。

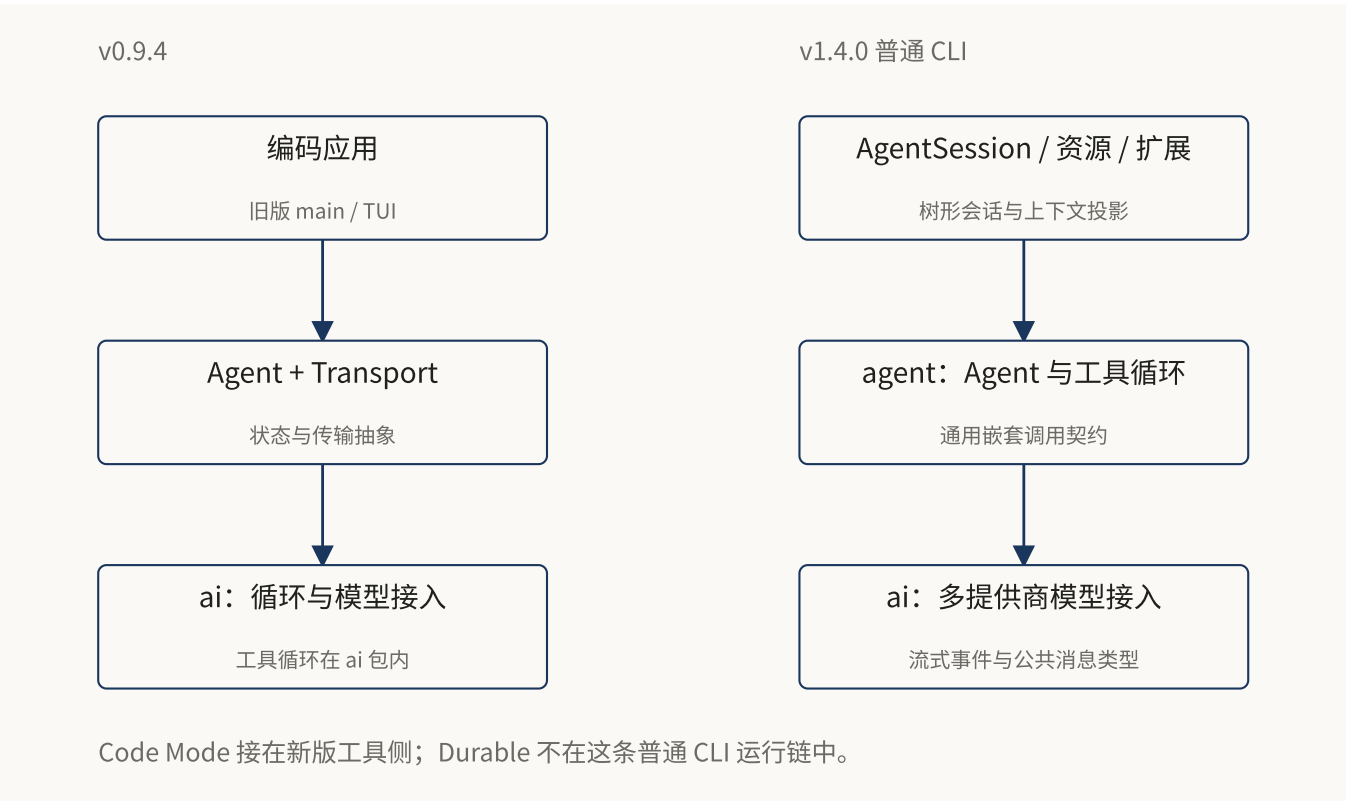
书中区分三类内容：

- 已核实行为：固定标签的文档、源码或发布记录能够支持。
- 教学模型：为了讲清职责而简化的图和伪代码。
- 示意算术：用于解释开销的假设工作量，不是实测性能。

不要被 diff 数字带偏

完整 Git 比较中，v0.9.4 到 v1.4.0 涉及 2,172 个变更文件；v0.99.2 到 v1.4.0 涉及 1,451 个；单独比较 v1.3.0 到 v1.4.0 则有 343 个。其中包含测试、文档、生成数据和实验代码的删除。尤其 v1.2.0 删除了尚未进入正式发布包的实验性服务端、客户端和插件栈。变更文件多、删除量大，并不等于正式 CLI 已经换成另一个分布式运行时。S2、S18

理解检查： 如果你以前用的是 v0.99.2，要知道 Code Mode 并非 v1.0 才出现；如果你比较的是 v0.9.4，则必须把中间接近一年的 harness 演进计算在内。



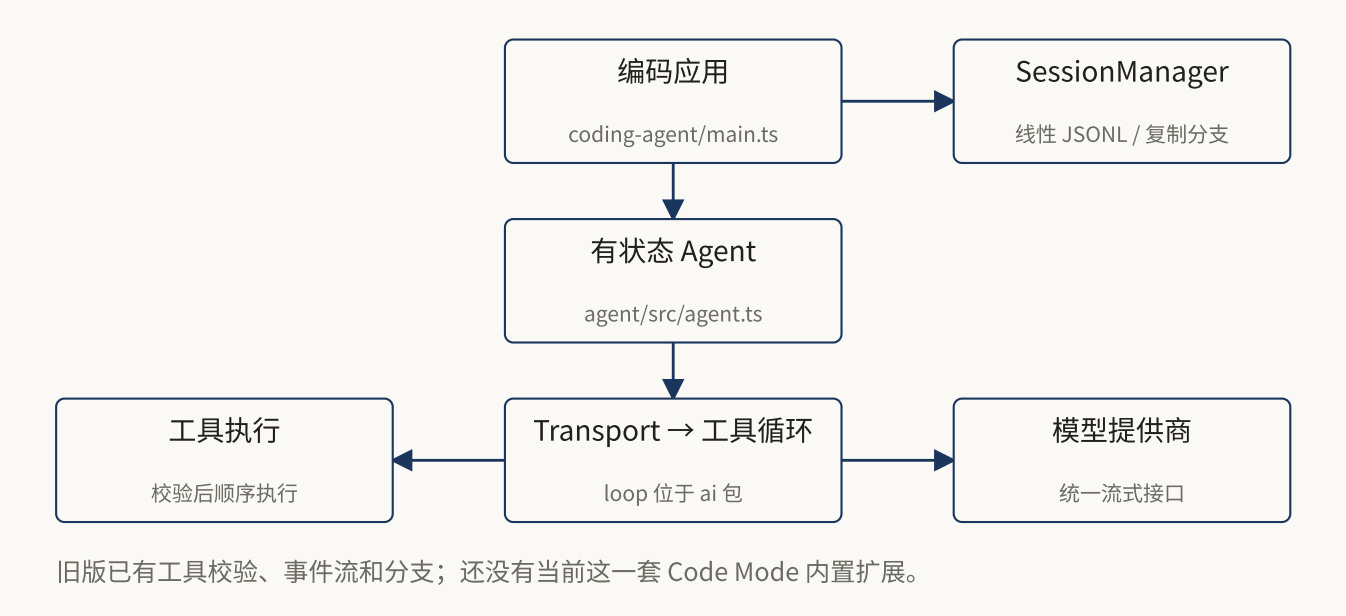
旧版与新版架构对照：循环迁到 agent，应用层形成 AgentSession 与扩展体系

左边是旧版职责所在的位置，右边是新版普通 CLI 的对应层。图中强调的是代码归属与装配边界，并不表示所有能力都在同一个版本里完成迁移。

第 2 章：v0.9.4 原本是怎样工作的

本章目标：先看清旧循环，再理解新增的编排层。

v0.9.4 已经把模型提供商接入、有状态 Agent、编码应用和终端渲染拆开。它并不是“一段 shell 加一次模型调用”。



v0.9.4 的职责分层

真正的循环在 `packages/ai/src/agent/agent-loop.ts`。有状态 `Agent` 在 `packages/agent/src/agent.ts`，接收 `AgentTransport`，通过 `transport.run( ... )` 遍历事件。编码应用负责把这些模块装配起来。S3、S4

跟着一次请求走

假设你说：“读 package.json，告诉我包名。”

Agent 构造用户消息，把应用消息转换成模型能理解的消息，再交给 transport。循环接收模型流式响应。如果响应中包含 `read` 调用，就按名称查找工具、校验参数、执行 `execute()`，把结果变成 `toolResult` 加入上下文，再请求模型给出答案。

下面是教学伪代码，不是逐字摘录：

```
while (hasToolCalls || queuedMessages.length > 0) {
  injectQueuedMessages();
  const assistant = await streamModel(context);
  for (const call of assistant.toolCalls) {
    const args = validate(call);
    const result = await findTool(call.name).execute(call.id, args, signal);
    context.messages.push(toToolResult(call, result));
  }
}
```

这里有两个历史事实。第一，工具参数校验早就存在，不能把它算作 Code Mode 才带来的能力。第二，旧循环通过带 `await` 的 `for ... of` 逐个执行工具；当前 Agent 支持同一响应中的多个调用并行执行。S4、S6

状态分别放在哪里

Agent 维护消息、当前模型、流式状态、待执行调用 ID 和消息队列。消息转换器负责把附件等应用数据变成模型输入。事件流让 UI 观察 `message_start`、`message_update`、`message_end`、工具执行和回合边界。

旧 `SessionManager` 使用 JSONL，保存会话头、消息、模型变更和思考等级变更。条目没有当前的 `id` / `parentId` 树形链接。`createBranchedSession()` 会新建文件，把分支点之前的消息复制过去。所以旧版并非没有分支，只是把历史复制到新文件，不同于当前在一个文件中切换树形分支。S5

那时还没有什么

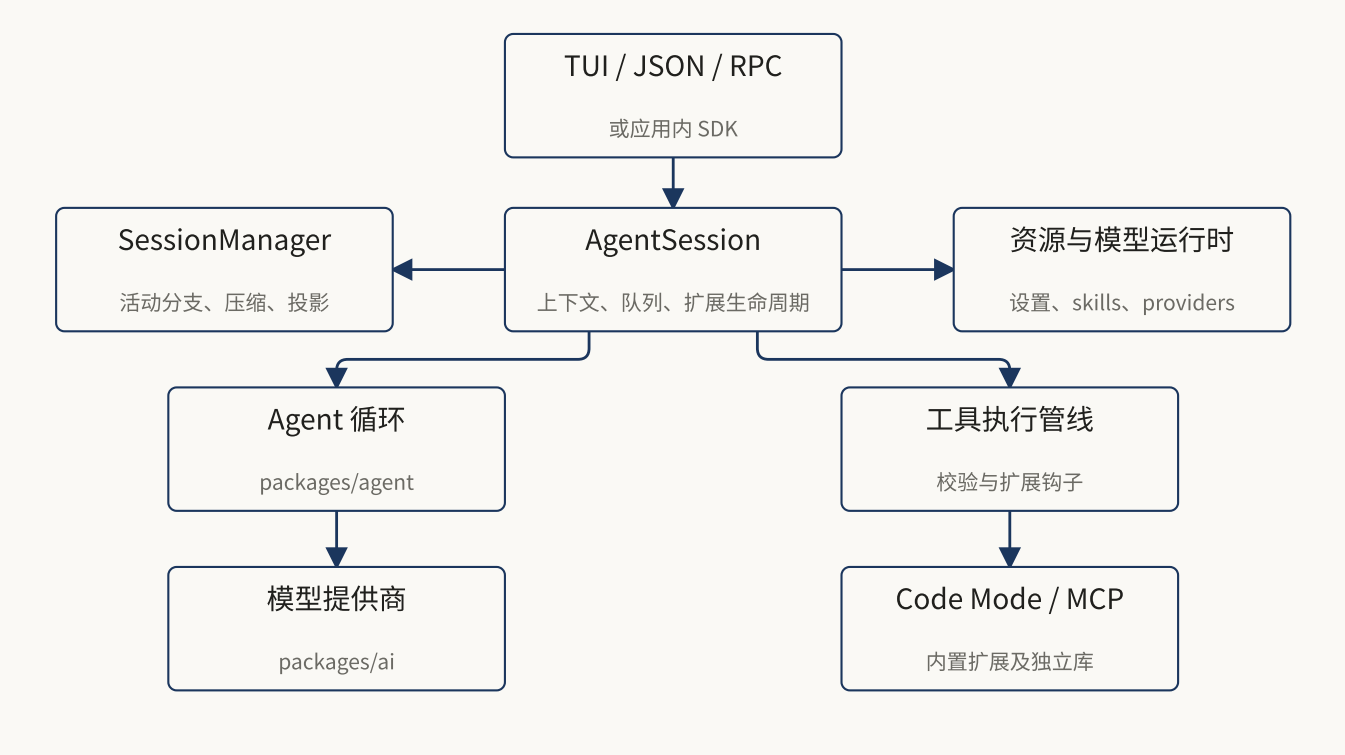
该标签没有当前这一套内置 Code Mode、MCP、tool search 组合，也没有后来统一的扩展系统。仓库还包含 `mom`、`web-ui`、`pods`、`proxy` 等应用或配套模块。说明多界面复用从早期就重要，但不意味着这些目录现在仍原封不动地存在。

练习： Anthropic 流式事件归一化应该放哪里？模型接入层。重画终端一行放哪里？TUI。判断是否继续下一轮模型请求放哪里？Agent 循环。文件位置虽变，职责判断仍然有效。

第 3 章：当前架构，分清 CLI 与独立基础库

本章目标：看到整张地图，但不把相邻模块当作同一条执行链。

v1.4.0 的 CLI 仍建立在有状态 `Agent` 上，不过循环已经并入 Agent 所在的包：`packages/agent/src/agent-loop.ts`。编码应用层提供 `AgentSession`、会话持久化、上下文投影、资源加载、扩展、模型运行时和不同交互接口。S6、S7



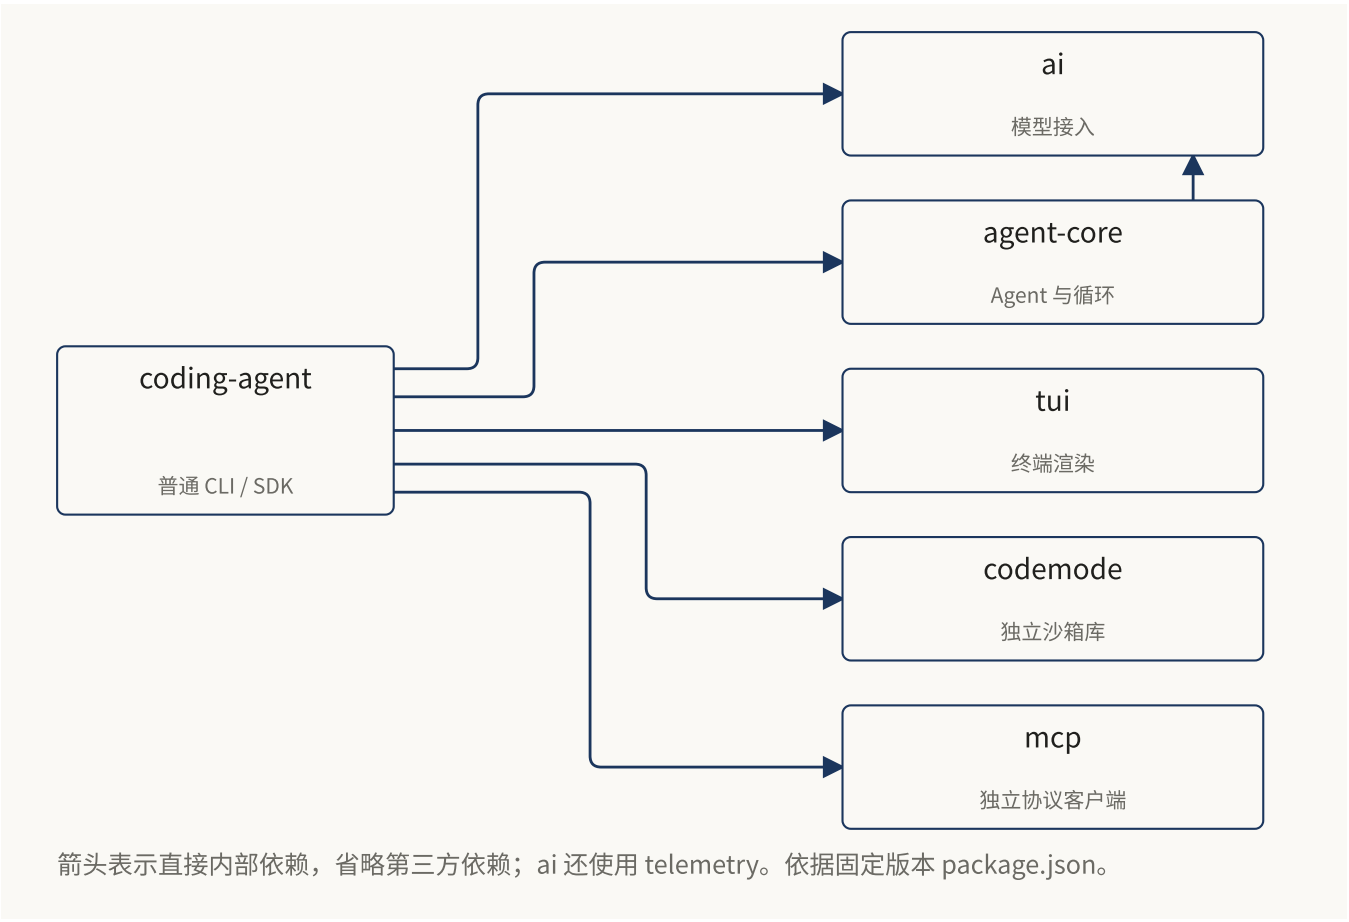
当前普通 CLI 的运行时职责图

这张图表达的是职责划分，不是完整的 npm 依赖图。Code Mode 和 MCP 通过 CLI 的内置扩展接入，没有替换 Agent 或模型接入层。

每个包负责什么

目录	主要职责	与普通 CLI 的关系
`ai`	多提供商模型、流式事件、公共内容类型	模型基础层
`agent`	有状态 Agent、模型/工具循环、队列、事件	核心循环
`coding-agent`	CLI、AgentSession、资源、扩展、会话、SDK、RPC	产品与 harness 层
`tui`	差分终端渲染	交互展示
`codemode`	独立 QuickJS 沙箱及脚本协议	被内置 Code Mode 扩展调用
`mcp`	独立 MCP 客户端	被内置 MCP 集成调用
`telemetry`	厂商无关的观测契约、类型与 schema 工具	配套基础库，`ai` 依赖它
`durable`	实验性持久会话、任务、文档运行时	独立 runtime，不是默认 CLI 内核
`env`	Durable 的远程执行客户端和 Rust daemon	可选远程基础设施
`chord`	类型化 runtime、文档状态、RPC 基础设施	Durable 使用它；CLI 在 v1.2.0 去掉了直接依赖
`evals`	仓库内的评估工具	开发工具，不是用户请求必经阶段

这些关系依据固定版本的 `package.json` 确认。根 README 的包表不是完整目录清单，部分新包未列入；反过来，仓库里存在某个包，也不意味着 CLI 依赖它。确认依赖关系时，优先查看 `coding-agent/package.json`。S8



普通 CLI 的实际内部包依赖：箭头表示直接依赖，不是请求执行顺序

上图专门回答“安装和维护普通 CLI 时，哪些内部包需要一起保持版本一致”。不要将它与上一张运行时职责图的调用方向混读，也不要因为仓库有 Durable，就把 Durable 画成 CLI 的必经内核。

用三个边界理解后面的所有章节

推理边界： 模型决定目标、调用和代码；Code Mode 中的常规循环、条件、聚合由 JavaScript 执行，不必每个中间结果都重新问模型。

上下文边界： harness 决定下一次模型请求看到什么。磁盘历史、UI 展示、嵌套调用记录和模型上下文不是同一份东西。

能力边界： 脚本只能调用注入的能力，但注入的 shell 工具可能拥有 Pi 进程的全部权限。JavaScript 沙箱不等于 shell 的文件系统沙箱。

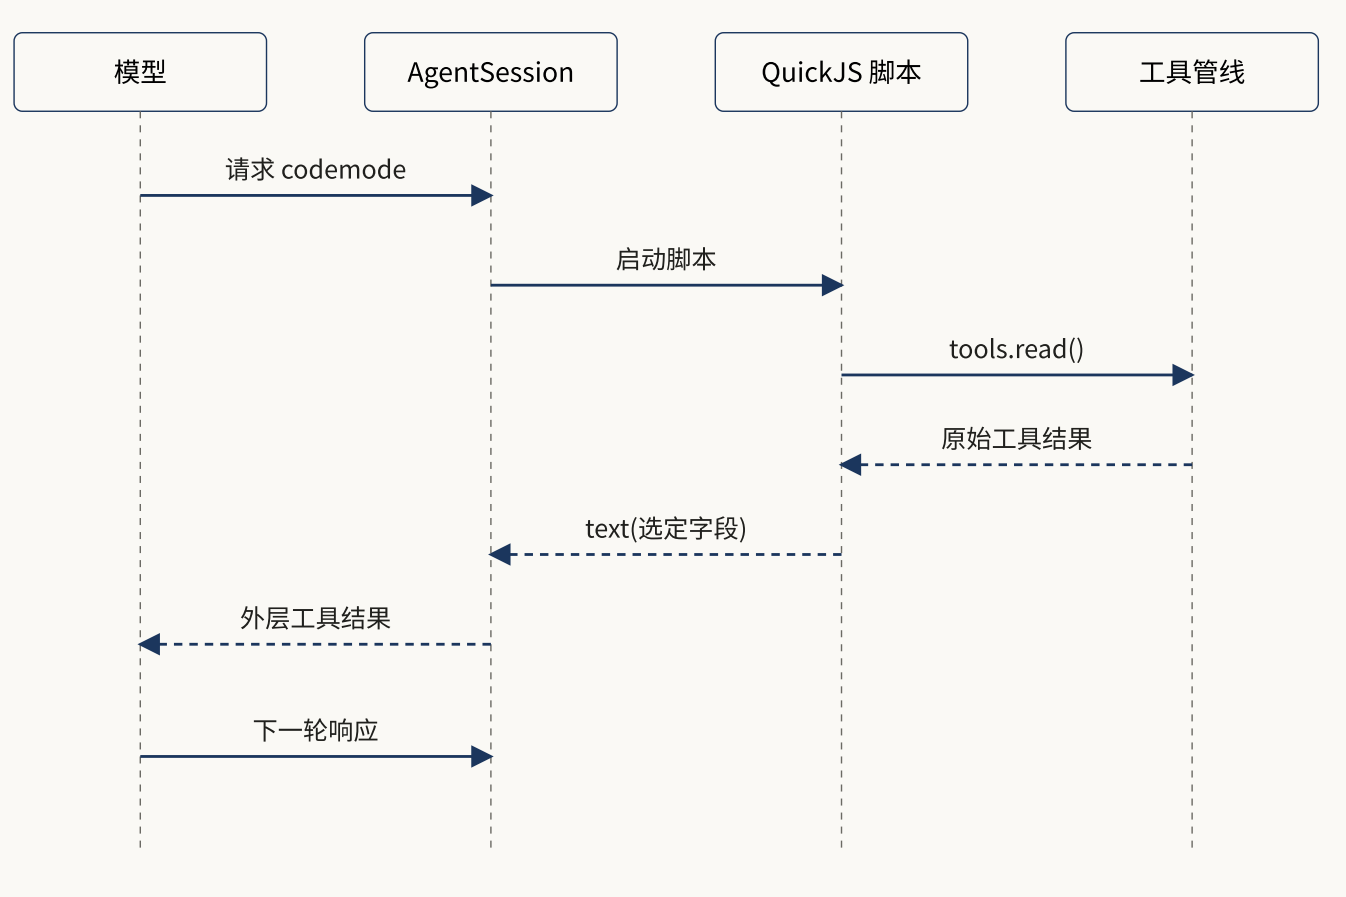
后面的章节沿着这三个边界展开。比起记住一串类名，这样更容易解释设计为什么发生这些变化。

第 4 章：一次请求的完整生命周期

本章目标：区分消息流、持久历史和模型输入。

理解新版最有效的路线不是先读所有类，而是跟一条请求走到底。

1. CLI、SDK 或 RPC 收到输入。提示模板可先展开，扩展可以处理命令或变换输入。
2. `AgentSession` 负责运行准备、模型与工具配置、压缩检查、扩展生命周期和队列。
3. `SessionManager` 从当前叶子追溯活动分支，重建已定稿的上下文。
4. harness 组合系统提示、分支消息、工具声明和模型设置，交给 provider。
5. provider 产生流式事件，Agent 归一化为消息和回合事件。
6. 如果 assistant 请求工具，则校验、触发扩展钩子、执行，记录结果。
7. 如果还有工具结果或队列需要处理，则继续；否则进入最终收尾。



请求、普通工具和 Code Mode 嵌套调用的时序

图中省略流式 token 与多轮重试，保留了最重要的边界：嵌套工具结果先回给脚本，而不是直接变成下一次模型输入。 S7、S9、S10

同一响应的并行，不等于 Code Mode

当前 Agent 的工具执行默认支持并行：先按顺序做调用前检查，再并行执行被允许的工具；完成事件按实际完成顺序发出，最终的工具结果消息仍按 assistant 源码中的调用顺序写入历史。需要共享状态的工具可以选择顺序执行。S6

这意味着：模型在一个响应里同时请求三次 `read`，不使用 Code Mode 也可能并行。Code Mode 多出的价值是在一个脚本中表达依赖、分支、过滤与聚合，并控制哪些结果跨回模型边界，而不只是“把串行变成并行”。

三种历史不要混淆

视角	保存或展示什么	用途
原始会话历史	消息、分支、压缩、上下文编辑、配置变化、自定义状态等	追溯、恢复、导出
UI 和执行事件	流式输出、嵌套工具进度、完成时长等	观察正在发生什么
模型上下文投影	活动分支经过压缩、上下文编辑、消息转换后的输入	下一轮模型推理

当前 JSONL 条目通过 `id` / `parentId` 组成树。`/tree` 可以从旧节点继续，同时保留被放弃分支。压缩追加摘要和保留边界，而不是删除原始历史；`context_edit` 可以让某个历史条目在未来模型上下文中被省略或替换，但不重写其原始记录。S11

压缩和 Code Mode 各解决什么

默认压缩阈值的概念是：

```
contextTokens > contextWindow - reserveTokens
```

Code Mode 在信息进入模型之前就做减量；压缩则是在上下文已经积累后，把早期内容总结成摘要。前者不能替代后者。普通工具调用也可以先截断输出；Code Mode 更适合按数据含义做结构化筛选。S12

例如运行测试得到很长日志。工具截断保留头尾，不知道你只关心三个失败断言；脚本可从结构化结果中选出失败项，再让模型理解原因。但如果你把全部日志 `text()` 出去，就没有获得这部分上下文收益。

v1.4.0：何时压缩，与摘要能输出多长是两回事

`compaction.reserveTokens` 仍决定自动压缩何时开始，但不再按它为摘要请求算一个固定输出上限。v1.3.0 的主摘要曾取 `floor(0.8 × reserveTokens)` 与模型输出上限中的较小者；当推理内容占用额度时，正文摘要可能还没写完就结束了。v1.4.0 改用模型输出上限，并在必要时让输入与输出共同适配上下文窗口。所以“移除固定上限”不表示输出无限，也不表示摘要一定成功。S12、S28

用教学数值手算：上下文窗口 128,000，预留 16,384，则超过 111,616 时触发自动压缩；旧主摘要按比例算出的上限约为 13,107。新版不会因为预留值相同，就把摘要仍然限制在 13,107。扩大预留值主要让压缩更早发生，不应再用它间接调整摘要长度。

分支总结也采用新输出预算。导出的 `generateSummary()` 和 `generateSummaryWithUsage()` 为兼容旧调用保留参数位置，但忽略原来的 `reserveTokens` 参数；维护自定义调用时要重新核对意图。`/compact 保留未解决问题` 之类指令也会传给被切开的回合前缀摘要，修复了此前这部分忽略指令的问题。

v1.4.0：截断恢复后，工具消息仍要成对

模型在输出上限处被截断，可能留下不完整的工具调用。历史转换不能只丢掉调用请求，却把对应工具结果交给下一轮 provider；孤立结果会使后续请求持续被拒绝。v1.4.0 修复了这条恢复路径。此处说的是模型响应截断后的协议一致性，不是工具长输出被截断后的 JSON 解析问题。S2

什么时候才算真的结束

SDK 的 `agent_end` 只代表一次底层 Agent 运行结束，之后还可能发生自动恢复、重试或排队工作。集成程序要确认 Pi 不再自动继续，应该关注 **`agent_settled`**。把两者当成同一个事件，会导致 UI 过早解除忙碌状态，或者脚本过早退出。S9

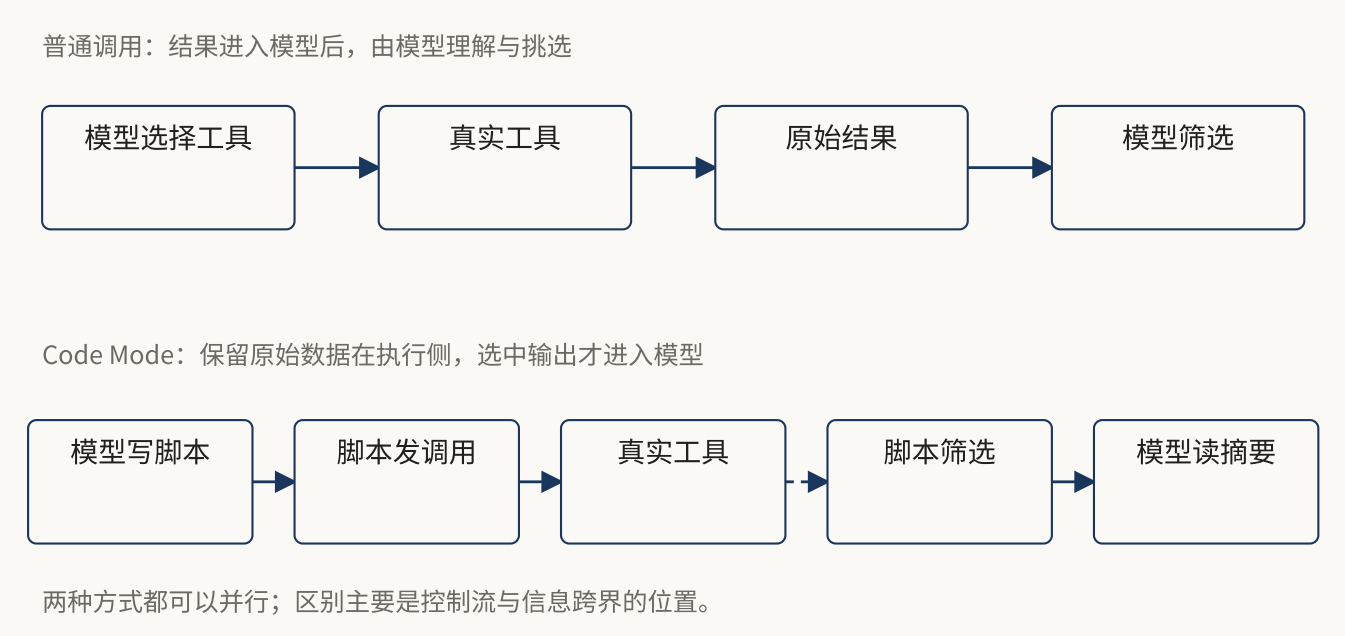
理解检查： 从树中切回旧节点，会不会回滚已经写入的文件？不会。会话分支描述对话历史，不是文件系统快照。

第 5 章：Code Mode 到底改变了什么

本章目标：能用一句话解释它，并知道何时不该使用。

让模型写一段调用工具的 JavaScript，常规编排在脚本中完成，只把主动输出的内容交还模型。

普通工具模式下，工具编排分散在 assistant 的工具请求及其后续模型响应中。Code Mode 把部分编排移到程序执行侧，模型看到一个外层 `codemode` 调用，脚本内部可以调用很多工具。底层工具仍然是真实工具。S10



普通工具与 Code Mode 的信息流比较

一个具体任务：检查三个 package.json

需求：“读取根目录、api 和 web 的 package.json，只告诉我包名与 scripts 里有没有 test。”

不用 Code Mode，模型可以请求三次 `read`，收下三个完整文件，再挑选字段；也可以请求 shell 直接聚合，或调用专门工具。Code Mode 不是唯一能做聚合的办法。

使用 Code Mode，可以表达为：

```
const paths = [
  "package.json",
  "packages/api/package.json",
  "packages/web/package.json",
];

const rows = await Promise.all(paths.map(async (path) ⇒ {
  const raw = await tools.read({ path });
  const pkg = JSON.parse(raw);
  return { path, name: pkg.name, hasTest: Boolean(pkg.scripts?.test) };
}));
text(rows);
```

假设三个文件都是未截断的有效 JSON，脚本内部会拿到全部内容，模型只收到选出的字段。`read` 返回的是字符串，不应写成 `raw.output`。如果读的是超大文件，被工具截断后就可能不是有效 JSON；应换成专门读取并解析的工具，或通过受控 shell 生成少量结构化数据。Code Mode 不会自动修复上游工具截断。

把控制流也写进去

如果其中一个包不存在，上一段的 `Promise.all()` 会让整个表达式失败。读取多个独立来源时，更实用的版本是：

```
const paths = ["package.json", "missing/package.json"];
const results = await Promise.allSettled(
  paths.map(async (path) ⇒ JSON.parse(await tools.read({ path })))
);
text(results.map((r, i) ⇒ r.status ⩵ "fulfilled"
  ? { path: paths[i], name: r.value.name }
  : { path: paths[i], error: String(r.reason) }
));
```

`Promise.allSettled()` 让失败和成功一起交给后续逻辑。它不是“忽略错误”，而是把错误变成你必须检查的数据。并发调用之间必须互不依赖，不能把“写文件”和“马上读取刚写的文件”随意放进同一个并发数组。

上下文收益怎么估算

下面只是示意，不是 Pi 性能测试。设有 N 个独立调用，每个原始结果 R 个字符，最终每项只需要 S 个字符。

```
全部原样返回：约 N × R
脚本选择字段：约 N × S + 外层包装
```

若 N = 12、R = 20,000、S = 300，数据量从约 240,000 个字符变成约 3,600 个字符，再加脚本和结果包装。字符不是 token，也不是费用；实际还受工具定义、模型分词、缓存和输出限制影响。这个例子只说明“把不需要的数据留在执行侧”的价值。

哪些事不值得套一层脚本

只读一个短文件，直接 `read` 通常更简单；要跑整个项目测试，直接 `bash` 就可能够了；需要长时间重型计算，QuickJS 也不比专门程序合适。不要为了使用 Code Mode，把本来一行能讲清的请求改成难读程序。

小结： 它的核心不是模型会写代码，也不是并行本身，而是把“工具输出到模型上下文”之间增加了一个可编程的数据处理层。

动手调一调：多少信息需要跨回模型?

修改调用数量与结果大小，观察字段筛选前后的字符量。这里只算数据字符，不估算 token、费用或实际耗时。

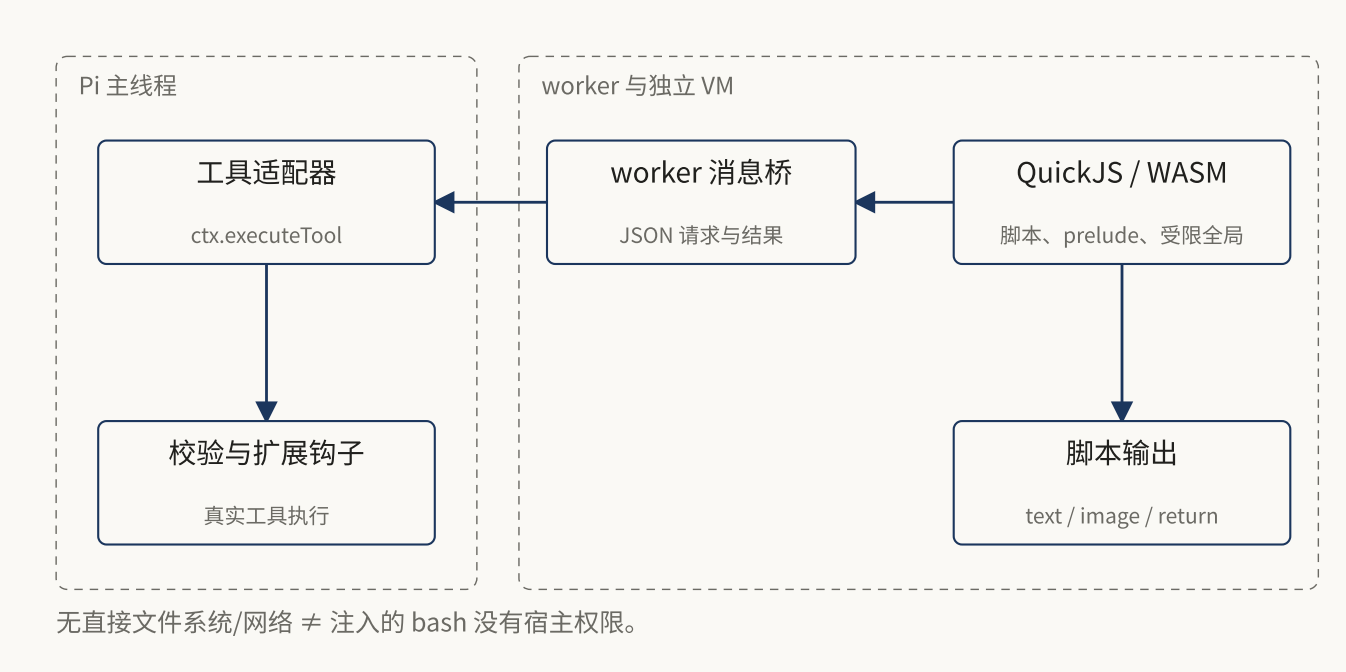
240,000 字符 → 3,600 字符

假设每项只返回 300 字符，忽略脚本与外层包装。工具本身可能已有截断；这不是实测速度对比。

第 6 章：拆开沙箱，看见真正的调用链

本章目标：知道脚本在哪里运行，权限检查在哪里发生。

普通 CLI 的 Code Mode 由两层组成：`packages/codemode` 提供通用沙箱；`coding-agent/src/extensions/codemode` 负责把它接到 Pi 的工具、会话、展示和模型运行时。前者没有 Pi 内部包依赖，因此也能脱离编码代理单独使用。S13



主线程、worker、WebAssembly 与 QuickJS 的边界

从源码追一次 tools.read()

1. `tool.ts` 定义 `codemode` 工具、输入形式和模型可见说明。
2. executor 读取当前可调用工具 `ctx.tools`，把每个工具包装成沙箱能力。
3. 创建 `CodemodeSandbox`，设置 QuickJS WASM、worker 入口、内存限制和 worker 准入控制。
4. `execute()` 启动 worker，在独立 WASM 实例中创建新的 QuickJS VM。
5. VM 内的 prelude 暴露 `tools`、`text`、`image`、`console`、`store` / `load` 等接口，桥接函数藏在闭包中。

6. 脚本调用 `tools.read( ... )`，消息经过 worker 桥返回主线程。
7. 主线程调用 `ctx.executeTool()`，进入参数校验及 `tool_call` / `tool_result` 钩子。
8. 结果被转换成脚本值，返回 VM；脚本选择性输出。
9. executor 关闭沙箱、处理状态写入、截断输出、保存图片、生成外层工具结果。

在 v1.4.0 的 `execute.ts` 中，关键语句仍是：

```
const outcome = await ctx.executeTool(tool.name, args, { signal: callSignal });
```

它解释了为什么“脚本里的工具调用”不是绕开工具链直接执行函数。已有扩展实现的拦截与权限确认仍然可以生效。不过 Pi 没有内置一套对每次调用逐一确认的默认权限系统；这里说的是扩展钩子可以执行权限策略，不是默认已经有一层强制审批。S14、S15、S25

为什么不用 Node 的 eval

脚本里没有 Node API、文件系统、网络、模块加载和定时器。不能直接使用 `process`、`require`、`fetch` 或 `setTimeout`，需要访问外部世界就通过注入工具。`eval` / `Function` 即使存在，也只能在同一个 VM 里生成更多代码，不凭空获得宿主能力。

QuickJS 是解释器，编译为 WebAssembly 后运行在 worker。worker 避免一段同步死循环卡住 Pi 主线程；WASM 实例分离 VM 内存；能力注入限制脚本可以接触的接口。这是分层设计，不是一句“用了沙箱所以绝对安全”。

限制属于哪一层

层次	典型限制或职责
脚本源格式	第一行可选 `// @options:`；错误位置或非法字段会报错
VM	CLI 每脚本 256 MiB 堆限制，无法分配时失败
宿主/worker	deadline、abort、worker 生命周期与数量限制
输出收集	16 Mi 字符及 100,000 个输出项目上限

层次	典型限制或职责
模型结果格式化	默认约 10,000 输出 token 预算，超长保留头尾并保存完整文本
底层工具	参数、外部进程、远程调用、工具自身截断与超时
操作系统或容器	文件、进程、网络与凭据的真正权限边界

这些限额不能混用。256 MiB 是 CLI 集成的选择，不是所有独立沙箱部署的通用默认；Cloudflare 默认限制又不同。外层输出 token 预算也不是 VM 内存限制。S10、S13

一个危险的误解

```
await tools.bash({ command: "某个有破坏性的命令" });
```

命令执行发生在工具能力背后，能接触什么取决于 Pi 进程或工具专属容器，不取决于 QuickJS 是否能直接读文件。需要强隔离时，应限制容器挂载、网络、账户和凭据；只限制 JavaScript 全局变量远远不够。

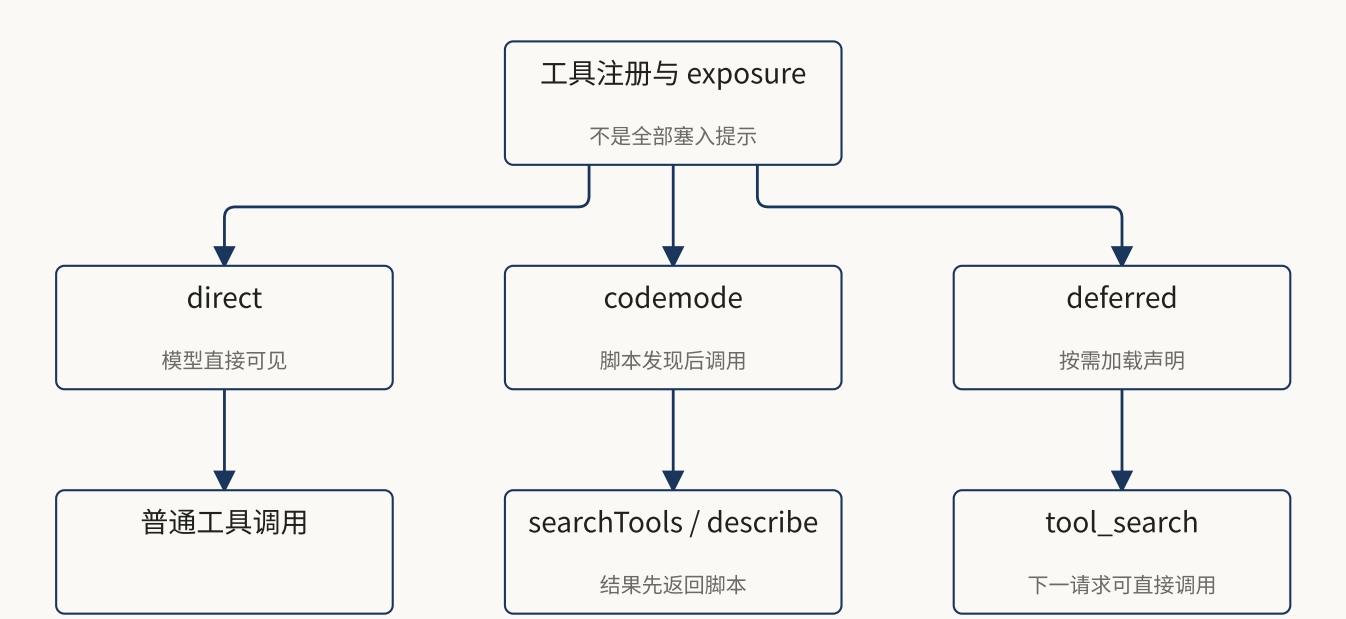
源码阅读顺序：`tool.ts` → `execute.ts` → `codemode/src/runtime/host.ts` → `worker.ts` → `vm.ts` → `prelude-source.ts`。先沿着一次调用走通，再研究声明生成和模型辅助接口。

第 7 章：工具太多时，怎样发现而不塞满提示

本章目标：分清“注册”“向模型声明”和“可被脚本调用”。

常见思路是把所有工具的名称、说明和参数 schema 都放进模型请求。工具少时这样做很直观；但面对几十个服务、几百个工具，它会撑大提示、干扰模型选择，工具集的变动还会波及缓存。

Pi 把这几件事拆开了：工具可以已注册却不直接声明给模型，可以供脚本调用却不出现在 Code Mode 说明里，也可以按需搜索后再声明。不可见不等于不可用，也不等于权限已被撤销。 S16、S17



MCP 的 codemode 与 deferred 都可被脚本调用；hidden 在两条间接路径中也不可达。

直接声明、脚本发现和工具搜索三条路径

MCP 的四种 exposure

MCP exposure	默认向模型声明?	脚本可调用?	常见用途
`direct`	是，受当前工具选择约束	是	少量高频工具
`codemode`	否，默认也不列入 Code Mode 描述	是	大多数服务，先发现再组合

MCP exposure	默认向模型声明?	脚本可调用?	常见用途
`deferred`	否；`tool_search` 可加载声明	是	希望发现后按普通工具直接调用
`hidden`	否	否	保留注册信息但使其不可达

MCP 默认使用 `codemode`。普通扩展工具还有 `model-only`，适合仅让模型直接调用、禁止其他工具间接调用的编排器或问答工具。不要把 MCP 配置表和扩展底层表机械合并：MCP 集成会处理命名空间和延迟发现，最终可达性还取决于禁用、过滤与活动集合。S15、S16

四个发现入口，各做一件事

```
const hits = await searchTools("search documentation", { limit: 3 });
text(hits);
```

- `ALL_TOOLS`：当前可调用目录，包含名称和说明。
- `searchTools(query, options)`：BM25 相关性排序，找候选。
- `describeTool(name)`：获得某个工具的说明与 TypeScript 声明。
- `describeNamespace(name)`：读某个命名空间的指令和工具信息。

三个查询 helper 都是异步接口，调用时必须 `await`。BM25 做的是文本检索，并不理解业务语义；搜索词和工具说明写得如何，会直接影响结果质量。发现之后要先确认参数，不能猜个名字就直接调用。S10

示意流程如下，其中 `hits[0]` 只是候选，必须读完说明再决定是否合适：

```
const hits = await searchTools("read documentation page", { limit: 3 });
if (hits.length === 0) return "没有找到候选工具";
text(await describeTool(hits[0].name));
```

发现结果会在这一轮交还模型，模型下一轮再据此编写准确的调用。发现和执行不必都挤在同一个脚本里。

codemode.mode 的 on 与 only

`on` 是默认模式：已声明的工具继续直接可见，同时附带脚本调用提示。`only` 则隐藏这些底层工具的直接声明，把调用入口集中到 Code Mode；但可调用的集合本身不会因为声明被隐藏而消失。

```
{
  "defaultTools": ["+codemode"],
  "codemode": { "mode": "on", "inlineBudget": 3000 }
}
```

`inlineBudget` 是对声明文本的 token 预算估计，大约按字符数除以四折算，并非精确分词。超出预算的工具交给发现接口查找。当前默认的 MCP 工具本就不会逐个写进 Code Mode 描述。`only` 属于呈现和编排策略，不提供更强的 OS 沙箱隔离。S17

为什么 MCP 不阻塞每次启动

从 v0.99.2 起，非 direct 服务器不再阻塞首个 prompt，而是先在后台连接；等到脚本点名某个服务器，或需要搜索全部工具时，再等待相关连接完成。当前用 `reachesTools(input)` 描述编排器可能触及哪些工具或命名空间，MCP 扩展据此等待必要的服务器。搜索整个目录意味着可能触及全部工具，所以要等更多服务就绪。S2、S15、S16

v1.2.0 将 MCP 与 Code Mode 解耦，意义也在这里：MCP 不再到处硬编码去“识别某个内置实现”，而是通过通用工具契约判断编排器的可达范围。替换同名编排工具时，需要一并提供相应的 `reachesTools` 契约。

一个容易造成权限误判的 CLI 细节

```
pi --tools read,codemode
```

在当前版本中，这条命令不会自动删除 MCP 工具，它们仍可能被脚本调用。要去掉 MCP，用 `--no-mcp`；按 MCP 名称筛选用 `mcp__` 模式；排除工具用 `--exclude-tools`。不能只读 allowlist 的表面含义，就当成完整的权限审计。S16、S19

第 8 章：结果、失败、并发与状态

本章目标：写出在真实失败中仍然可理解的脚本。

Code Mode 最容易写错的地方在返回值和失败契约，而不是语法。不要假定所有调用都返回字符串，也不要假定失败一定以 throw 的形式出现。

三种常见结果

工具	脚本通常拿到什么	需要检查什么
`read` 读文本	字符串	是否被截断，是否符合预期格式
`bash`	`{ output, exit_code, truncated, full_output_path?, … }`	`exit_code`，即使 Promise fulfilled 也可能执行失败
MCP 工具	`CallToolResult`，包括 `content`、`structuredContent`、`isError`	`isError` 与实际字段，不要只读第一条文本就宣布成功

声明了 output schema 的工具可以把结构化值交给脚本，错误结果也可能携带结构化值。校验失败、被拦截、没有对应数据等执行异常可以 reject。MCP 会保留完整的结果对象，所以 `isError` 必须显式检查。最终以发现接口返回的声明和该工具的契约为准。S10、S14、S16

```
const result = await tools.bash({ command: "npm test" });
if (result.exit_code !== 0) {
  text({ passed: false, tail: result.output.slice(-4000) });
} else {
  text({ passed: true });
}
```

对 MCP，下面仅表达检查方式，工具名和参数都是教学占位，需先用发现接口确认：

```
// 伪代码：先发现真实工具，不要原样运行。
const result = await tools.mcp__docs__search({ query: "session" });
if (result.isError) throw new Error(JSON.stringify(result.content));
text(result.structuredContent ?? result.content);
```

两个层次的成功

`Promise.allSettled()` 返回 fulfilled，只说明 Promise 没有 reject，既不说明 shell 退出码为零，更不说明业务成功。可靠脚本会先看 Promise 状态，再看结果里的错误标志或退出码。

类似地，独立沙箱 `sandbox.execute()` 遇到脚本错误时通常返回 `{ ok: false, error }`，而不是直接 reject。脚本、宿主调用和模型 API 处在不同层次，错误表示并不通用。

await 是生命周期的一部分

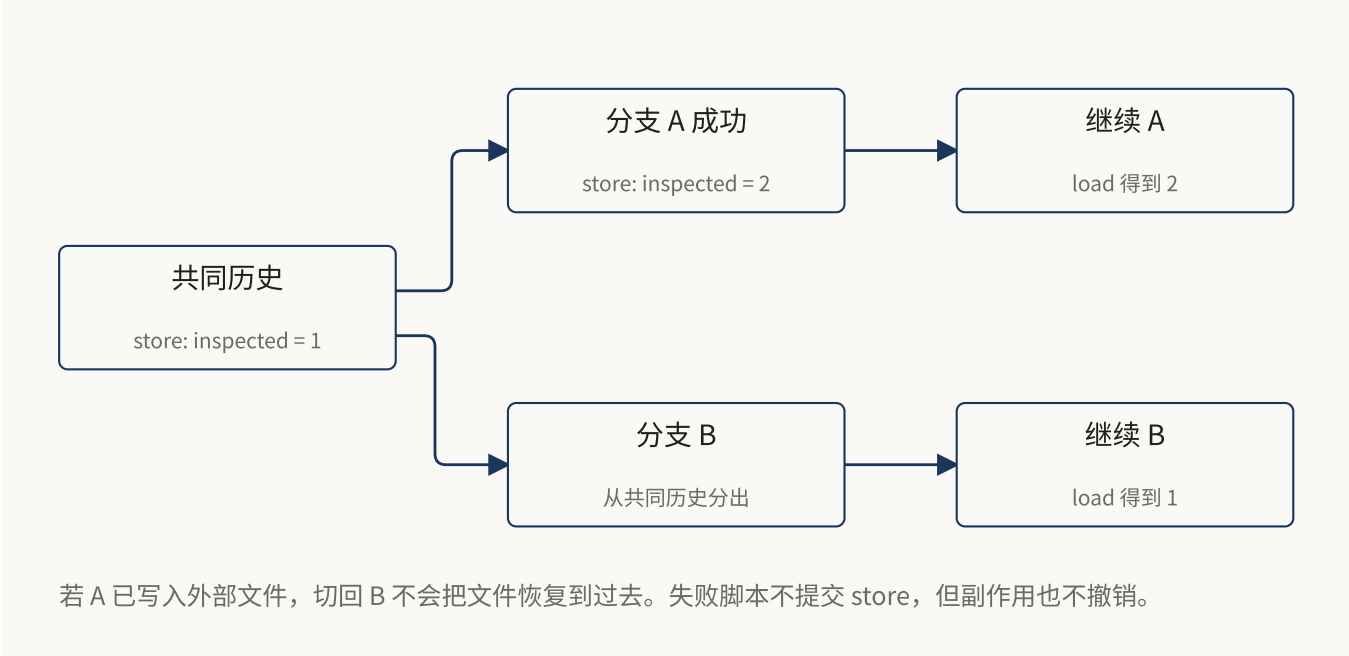
```
// 错误示例：脚本可能先结束，未完成调用会被取消。
tools.read({ path: "package.json" });
return "完成";
```

```
// 正确示例：确认依赖工作已完成。
const source = await tools.read({ path: "package.json" });
text(JSON.parse(source).name);
```

脚本结束时，尚未完成的调用会被请求取消；已经完成的外部副作用不会回滚。`Promise.all()` 因为其中一项失败而提前 reject，也可能让外层脚本结束，进而取消其他仍在进行的调用。彼此独立的读取适合用 `allSettled()`，有依赖关系的操作则按顺序执行。

store 不是数据库事务

`store(key, value)` / `load(key)` 保存小型 JSON 状态。CLI 只有脚本成功后，才把变更追加为 `codemode-store` 自定义会话条目；恢复和树形分支都只重放当前路径上的状态。单值 JSON 长度上限为 262,144 字符，总量为 1,048,576 字符。S10、S14



若 A 已写入外部文件，切回 B 不会把文件恢复到过去。失败脚本不提交 store，但副作用也不撤销。

分支相对的脚本状态，与外部文件副作用的区别

```
const count = (load("inspected") ?? 0) + 1;
store("inspected", count);
text({ count });
```

如果脚本后面 throw，状态写入不会提交；但此前通过 `write` 修改的文件可能已经变更。所以“失败不提交 store”并不等于“失败回滚整个脚本”。同理，在分支 A 保存的游标不会自动出现在从更早节点分出的分支 B 中，而文件系统对两者仍是同一份现实。

适合存：查询游标、选中的 ID、短摘要。不要存大型日志、图片 base64、完整仓库文件；大数据应由文件或外部服务承载。

取消不代表 worker 已经退出

CLI 默认最多允许同一 Pi 进程中两个 Code Mode worker 存活，跨会话共享；v1.4.0 可以用环境变量 `PI_CODEMODE_MAX_WORKERS` 指定正整数上限，非法值回退到默认 2。Bun 下，某些不轮询中断的内建操作可能在返回取消结果后继续运行，直到该操作结束。v1.3.0 的修复把“对用户立即返回取消”和“实际 worker 退出后释放名额”拆开，避免重复取消积累残留 worker。S2、S13、S14

这个区别很通用：响应完成、任务停止、资源回收完成，是三个不同时间点。 不能在 timeout 返回的瞬间就把并发名额无条件释放。

v1.4.0：容量用尽时先排队，不是立即失败

v1.3.0 引入真实 worker 数量限制，但名额满时会立即拒绝新脚本。v1.4.0 的 `reserveCodemodeWorker()` 先把等待者加入队列；`admitCodemodeWorkers()` 按到达顺序放行，`releaseCodemodeWorker()` 在实际释放后继续准入。S26

等待最多 60 秒，并且计入脚本整体的 `timeout_ms`。假设脚本总时限 10 秒，排队花掉 8 秒，剩下最多只能执行约 2 秒，不会在拿到名额后再补一份完整的 10 秒。等待超时或被取消的请求会从队列移除；没有获得名额就不会启动 VM。

“两个 worker”并不等于“脚本里只能并发两个工具”。脚本中彼此独立的工具调用不会逐项占用这两个名额；`models.classify()` 和 `models.generateImages()` 另有每脚本最多 4 项在途调用的限制。调高 worker 上限会增加潜在的内存与外部调用压力，并不等于免费提升吞吐。

排队也不等于解决所有相互等待：脚本持有 worker，又等同进程中的另一个脚本获取名额，仍可能形成资源等待。60 秒等待上限提供失败出口，不提供无限递归子代理能力；脚本不能直接启动另一个 `codemode`。

四类常见错误的处置

症状	先检查什么	合理恢复
`tools.X` 不存在	拼写、标识符规范、工具是否可达	重新发现并描述工具，不反复猜名字
JSON.parse 失败	是否读到截断输出、日志或错误页面	换结构化工具或缩小读取内容
等待空闲 worker 超时	全进程名额、残留 worker、相互等待和总 deadline	v1.4.0 已自动排队；先查占用，不做高频重试
超时或部分成功	哪些调用已产生副作用	查明实际状态，再决定是否重试；写操作需幂等策略

第 9 章：扩展、模型与界面，哪些没被 Code Mode 替代

本章目标：知道新增功能应该放在哪一层。

定制需求并不都由 Code Mode 承担。模型生成的短程序编排归它；安装到 harness 的可执行行为归扩展；按需指令归 skill；复用输入归提示模板；配色归主题。这些能力彼此互补。

扩展：从分散机制到一个入口

v0.35.0 把 hooks 与自定义工具统一成 extensions，并把文件式 slash commands 改称 prompt templates，避免和真正注册的命令混淆。当前 TypeScript 扩展工厂接收 `ExtensionAPI`，可以注册工具、命令、事件处理器、模型提供商、渲染器等。S2、S15

最小例子：

```
import type { ExtensionAPI } from "@earendil-works/pi-coding-agent";

export default function (pi: ExtensionAPI) {
  pi.registerCommand("hello", {
    description: "显示问候",
    handler: async (name, ctx) => {
      ctx.ui.notify(`你好，${name || "世界"}`, "info");
    },
  });
}
```

扩展直接运行在 Pi 进程中，能够接触文件、凭据与会话，不受 QuickJS 脚本那组全局变量限制。加载不可信扩展，比阅读一份不可信文档具有更直接的执行风险。

生命周期与状态放置

扩展工厂负责注册，不宜直接启动 watcher、socket、定时器。因为有些命令只加载扩展，并不启动会话。长寿命资源应在 `session_start` 或实际需要时开启，并在 `session_shutdown` 幂等清理。

分支相关工具状态可以放工具结果 `details`；不进入模型的持久数据用 `appendEntry()`；希望进入模型的自定义内容用 `sendMessage()`；跨会话数据用外部存储。重建状态应读取 `getBranch()`，不是遍历整个文件把其他分支也合并。S15

Provider 仍然承担协议适配

Code Mode 不会消除 Anthropic、OpenAI、Google 等协议差异，模型接入、流式归一化与内容转换仍由 `ai` 层负责。v1.3.0 起切换模型时会丢弃由另一模型产生的历史 thinking 块，避免它们被当作普通文本交给新模型；特定提供商的缓存保持也属于 provider 相关行为，不能据此认为所有模型切换都没有代价。S2

脚本中的 `models.*` 可访问模型目录、运行分类器、生成图片，但不能把聊天模型当作任意子 Agent 在脚本中调用。分类和生成图片可能计费，其 usage 会纳入会话成本；要检查 `stopReason` 与 `errorMessage`。图片要用 `image(block)` 展示，不要用 `text()` 打印 base64。S10

v1.4.0：把图片交给分类器，而非打印 base64

`models.classify()` 新增了 `images` 输入，适用于受支持的 Jev、Clef 服务以及具备相应能力的模型。模型类别是 classifier，并不代表它就支持图片：先查目录中的 `input` 是否包含 `"image"`，再按 provider 核对格式与数量限制。图片分类与生成图片是两项不同的能力。S10、S27

下面是 `examples/scripts/06-classify-image.js` 的契约示例。实际运行需要可用的图片分类模型、对应凭据和本地 `screenshot.png`，可能产生费用：

```
const candidates = await models.getAvailableOfType("classifier");
const vision = candidates.find(m ⇒ m.input?.includes("image"));
if (!vision) throw new Error("没有可用的图片分类器");
const photo = await tools.read({ path: "screenshot.png" });
if (photo.type ≠= "image") throw new Error("需要图片块");
const result = await models.classify(vision, {
  state: { task: "检查页面布局" },
  images: [photo],
  questions: {
    broken: {
      type: "bool",
      instructions: "图片中是否有重叠或被截断的内容? ",
      criteria: { true: "存在布局缺陷", false: "未发现布局缺陷" },
    },
  },
});
if (result.stopReason ≠= "stop") {
  throw new Error(result.errorMessage ?? result.stopReason);
}
const answer = result.answers.broken;
if (answer?.type ≠= "bool") throw new Error("分类回答类型不符");
text({ probability: answer.probability });
```

`probability` 是模型判断的概率，不是经过本书验证的页面缺陷率，也不能证明图片没有问题。本书仅用替身检查调用结构、错误处理和不输出图片内容，没有调用真实分类服务。

代理兼容尤其需要注意：各 System One 服务接收图片的格式不同。`compat.imageInput` 和 `sendImageOptInHeader` 可在 provider 层配置；直接把请求改发 OpenRouter，却继续使用 TypeSafe 的 assets 形态，可能出现请求成功但图片被忽略。v1.4.0 新增的 `models-configuration.md` 从 schema 生成字段参考，按实际代理协议查证，不猜兼容选项。S29

恢复会话与扩展弹窗也有边界修复

v1.3.0 已能恢复分支记录过的活动工具；v1.4.0 进一步处理工具注册晚于分支记录的情况，例如会话开始后才安装的扩展。分支没有显式增删的工具默认可活动，但 `defaultActive: false` 仍应生效。恢复之后要检查实际可调用的集合，不能把这项修复理解成强制启用所有工具。

交互式扩展同时打开 `select`、`confirm`、`input`、`editor` 或 inline `custom()` 时，新弹窗不再让先前 Promise 永久悬挂；关闭当前弹窗会回到前一个。这修的是交互生命周期，不是给扩展增加 OS 权限隔离。S2

选择哪种集成方式

需要	优先接口	注意事项
人在终端中交互	TUI	v1.0.0 起默认全屏，可切回 regular
一次性自动化	`--print`	一次运行后退出
消费事件流	`--mode json`	stdout 为 JSONL 协议
非 TypeScript 宿主长期控制	RPC	stdin 命令，stdout 响应和事件
Node/Bun 应用内嵌	SDK	宿主负责生命周期、资源和事件绑定
只想执行受限工具脚本	独立 `pi-codemode`	不必引入整个编码代理
需要持久任务恢复	实验性 `pi-durable`	独立 API、存储与重放策略

TUI 是事件消费者和交互层，不是业务循环本身。RPC 与 SDK 不需要另写一套 Agent 算法，它们驱动的是同一套 session/agent 机制。自定义 UI 要区分 `ctx.hasUI` 与终端专属组件，不能假定 print 模式下也有确认框。S7、S9、S15

SDK 的一个关键差异

CLI 会加载内置 Code Mode、tool-search、MCP 扩展；SDK 默认不会替你装好这三者。需要通过 `DefaultResourceLoader.extensionFactories` 添加，并在建立会话后 `bindExtensions()`，让 `session_start` 触发 MCP 后台连接。本书 `examples/sdk-codemode-mcp.ts` 保存了该版本官方示例。S20

设计练习： “每次调用 shell 前做企业策略校验”应该写进临时的 Code Mode 脚本吗？不应该。可审计的扩展策略应当实现在工具边界，真正的权限边界则用 OS/容器限制补上。模型生成的代码不是执行强制安全策略的合适位置。

第 10 章：从 0.99.2 到 1.4.0，具体差了什么

本章目标：把长期演进、1.3.0 基线和 1.4.0 增量分开。

如果你的“0.9.xxx”其实是 0.99.2，前面很多机制你已经有了：Code Mode、独立 `pi-codemode` 包、工具发现、MCP、树形会话、统一扩展，并不是升级到 1.4.0 才第一次出现。下面只看这个较短区间。S2、S21

版本	Code Mode 及相关架构变化	对使用者的影响
1.0.0	缩短模型可见说明，增加错误恢复提示；加入 `models.generateImages()`	工具脚本提示更小，可以生成图像；探测工具是否存在要用 `in`
1.0.0	从 `pi-agent-core` 移除实验性 AgentHarness 与相关导出	依赖旧实验 API 的 SDK 使用者必须迁移，普通 CLI 不因此换内核
1.0.1	输出硬上限，防无限 `text()` 撑爆宿主；MCP 项目覆盖等	输出也受资源治理，不能只关心 VM 内存
1.0.3	`image()` 同时保存临时图片文件	后续回合可复制和引用图片路径
1.0.4	内建对象冻结；读图返回图片块；MCP 工具过滤规则修复	不可依赖修改 Array 等原型；图片可从 read 传给 image
1.1.0	CLI `--tools +name/-name`；发现 helper 的异步说明；输出项目分隔	增量启用工具更方便，多段结果更容易识别
1.2.0	声明显示 schema 约束；`reachesTools`、命名空间 aliases；MCP 解耦	工具编排器可替换，不必绑定特定内置实现
1.2.0	远程/inline 沙箱、portable 入口、确定性 `sandbox.start()`	独立包可部署到 Cloudflare，给持久重放提供基础
1.2.0	Durable 加入可恢复的 Code Mode；删除 CLI 未发布服务端实验栈	需要恢复的应用有新路径，但不可照旧实验目录继续开发
1.3.0	取消结果不等待实际退出；按真实 worker 生命周期限制容量	timeout 更及时，重复取消不会无上限积累 worker

版本	Code Mode 及相关架构变化	对使用者的影响
1.3.0	恢复会话时保留活动工具；内部 Pi 依赖固定到精确版本	恢复后的工具集更一致，减少混装不同内部版本
1.4.0	worker 满时排队，最多等待 60 秒；可调整全进程 worker 上限	并行脚本不再立即因容量不足失败，等待仍消耗总 deadline
1.4.0	压缩及分支摘要使用模型输出上限	`reserveTokens` 只决定压缩触发时机，不再间接限制摘要长度
1.4.0	图片分类输入、provider 分类器兼容字段、配置字段参考	可用结构化问题检查图片，但要核对模型能力、协议与费用
1.4.0	截断工具消息、晚注册扩展工具与并发弹窗修复	恢复后消息和工具更一致，交互 Promise 不再被新弹窗遗留

从 v1.3.0 升到 v1.4.0，优先验哪四件事

1. 在隔离测试进程中占满 worker，再发新脚本，观察它等待后启动或到期失败；检查等待时间是否计入总 deadline。
2. 用支持推理的模型执行长会话压缩，确认没有继续将 `reserveTokens` 当摘要长度旋钮；对分割回合检查自定义摘要指令。
3. 对图片分类保留“无可用模型”“服务失败”“仅文字模型”反例，不把 Promise fulfilled 当业务成功。
4. 从旧会话恢复、切换树形分支并加载扩展，核对活动工具；注入模型输出截断后核对工具请求与结果仍然配对。

这些是集成验收建议，不是本轮全部已运行的测试。1.4.0 的 Rex 终端支持、退出模式清理、Linux 挂起后的剪贴板和中文标点旁 Markdown 渲染也有改善，但没有改变前面所画的 Agent / AgentSession / Code Mode 职责分层。S2

“约少 40% token”到底指什么

v1.0.0 变更日志给出的例子是：默认工具并启用 Code Mode 时，一个 GPT-5.6 请求的提示规模从约 5,300 降到约 3,300 token。减少来自说明精简、按需阅读模型 API 文档、避免重复声明等。这是上游记录中的特定场景，不是本书实测，也不表示任何项目、模型、工具数量下都少 40%。S2

三个明确的迁移断点

探测工具存在性。 新版访问未知成员可能抛出带近似匹配建议的错误。旧代码 `typeof tools.someName` 也可能触发属性读取，改用 `"someName" in tools`。S21

MCP 类型声明。 独立包在 v1.2.0 移除了 `MCP_TYPESCRIPT_PREAMBLE` 和 `mcpStructuredContentSchema()`。输出 schema 直接描述完整返回对象，声明渲染不再依赖一个悬空的 `CallToolResult<T>` 名称。消费这些底层导出的应用要更新。S21

独立沙箱 close()。 v1.3.0 中结果和 `close()` 在请求关闭后即可 settle，但不代表 worker 已退出。自己管理资源池时，要用 `onWorkerStarted(exited)` 或 `acquireWorker()` 的释放回调追踪真实退出，不能照旧在结果完成后就释放容量。S13、S21

不要继续照旧实验目录做设计

v1.0.0 对 `pi-agent-core` 的清理与 v1.2.0 对 CLI 实验栈的清理是两件事。前者移除了该包的旧实验性 harness 导出；后者移除的 client/protocol/server 栈从未进入正式 coding-agent 发布包。做源码研究时能看到它们，但不能据此把它们都当作稳定产品 API。S18、S22

第 11 章：独立沙箱、云端执行与 Durable 重放

本章目标：分清三个看似相近、恢复保证完全不同的架构。

“Code Mode 可以恢复”这句话缺少主语。普通 CLI、独立沙箱库、Durable 扩展提供的保证并不相同。

形态	谁拥有工具与状态	中途崩溃后怎样处理
普通 CLI Code Mode	AgentSession 与扩展	已成功提交的小型 store 可恢复；没有普通脚本指令级自动续跑保证
独立 `CodemodeSandbox.execute()`	你的宿主	你自己管理持久化；一次执行不自动变持久任务
`sandbox.start()`	宿主驱动的确定性 VM	提供可重放机制，宿主仍需日志与调度
实验性 `pi-durable/codemode`	Durable Harness、存储、任务与 journal	重启后重放已记录结果并继续；未完成外部调用服从各自 replay 策略

11.1 不用整个 Pi，也能用沙箱

独立 `pi-codemode` 的核心接口是注入工具、执行脚本、读取结构化执行结果。工具函数在宿主执行，VM 只保留受限 JavaScript 环境。S13

```
import { CodemodeSandbox } from "@earendil-works/pi-codemode";

const sandbox = new CodemodeSandbox({
  timeoutMs: 10_000,
  tools: [{
    name: "lookup",
    execute: async ({ id }) ⇒ ({ id, title: `条目 ${id}`, privateNote: "不输出" }),
  }],
});

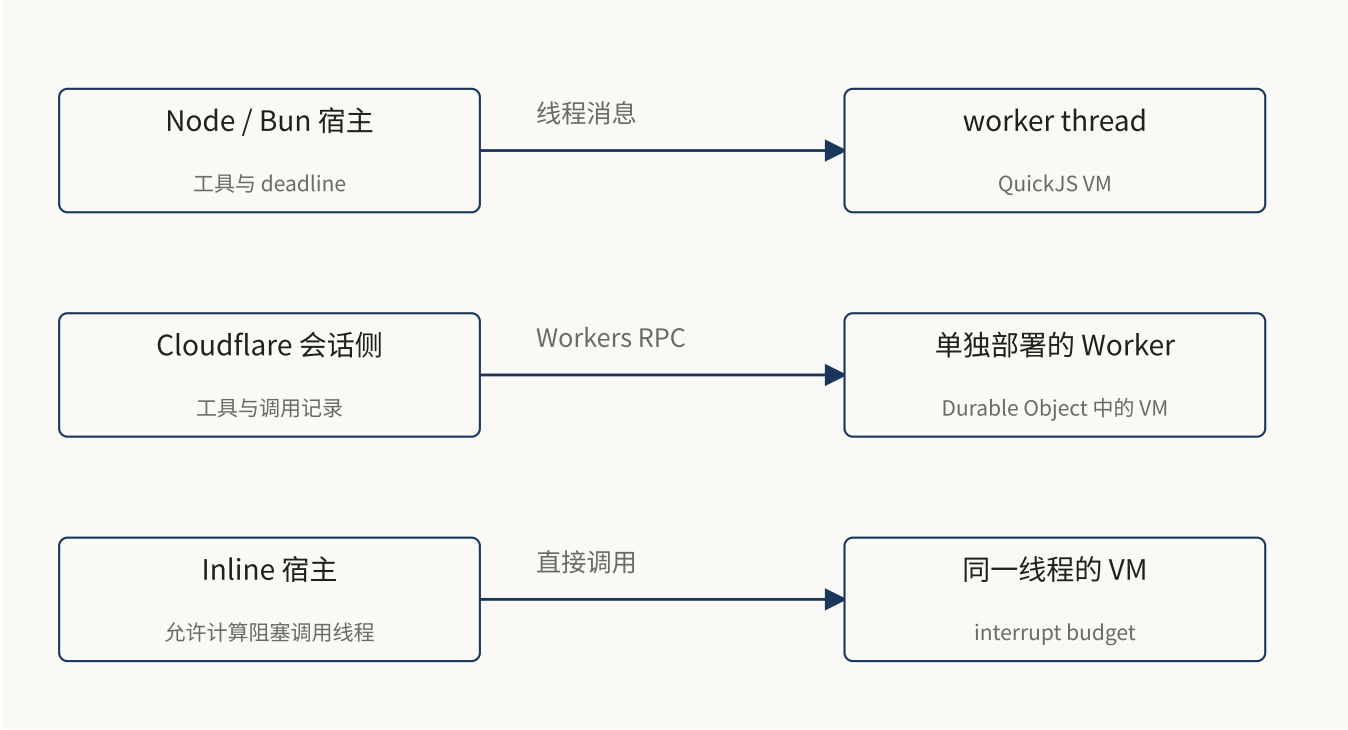
try {
  const result = await sandbox.execute(`
    const row = await tools.lookup({ id: 7 });
    text({ id: row.id, title: row.title });
  `);
  if (!result.ok) throw new Error(result.error.message);
  console.log(result.output);
} finally {
  await sandbox.close();
}
```

这是独立库示例，直接注入自己的可信函数。若要嵌入现有 Agent，不能图省事直接调用原始 `tool.execute()`，否则会绕过既有验证和钩子。官方 CLI 走 `ctx.executeTool()`；低层 Agent 应使用对应的工具调用管线。S13

11.2 为什么 Cloudflare 要把 VM 放进另一个 Worker

Node/Bun 用 worker thread 把计算隔离出主线程。Cloudflare 没有同样的 Node worker 环境，且 QuickJS 同步计算会阻塞承载它的 isolate。

v1.2.0 新增 `RemoteCodemodeSandbox`：工具和调用记录留在会话一侧，VM 放到单独部署的 Worker 中的 Durable Object，每次工具调用通过 Workers RPC 回到宿主。这里的 Durable Object 是 Cloudflare 基础设施，不等于 `pi-durable` 包。S13、S21



三种沙箱部署方式

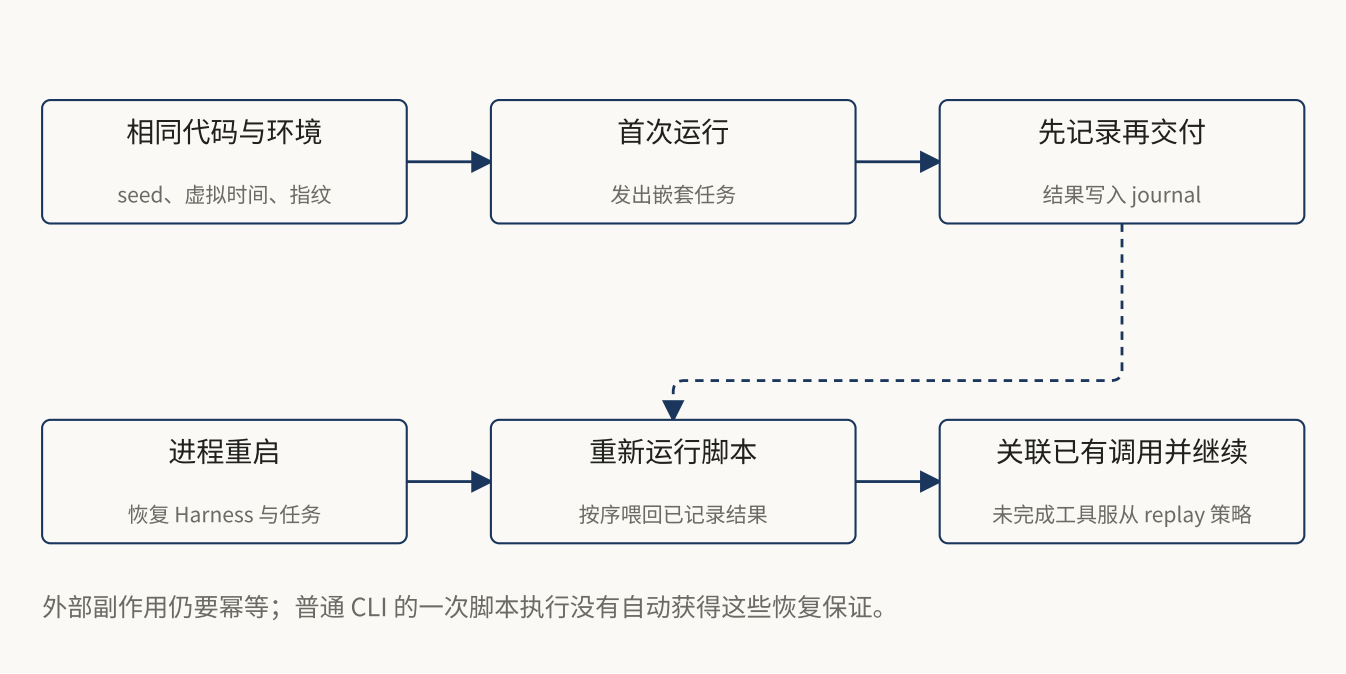
上游 README 记录了一项特定 Cloudflare 测试：让脚本持续计算十秒，放在会话对象内或由它加载的 Dynamic Worker 会延迟其他会话请求约十秒，单独部署的 Worker 则约为 50 ms。该数字来自上游环境测量，用来说明部署边界的选择，不保证本地环境或你的账号得到相同结果。

Cloudflare 还有两个限制需要单独理解：计算不 yield 时，墙钟 timeout 不足以约束 CPU，要使用 interrupt budget；远程 abort 可以先结束调用侧等待，VM 要到下一次工具调用或耗尽预算时才停。远程默认每 VM 32 MiB，不能套用普通 CLI 的 256 MiB。

`InlineCodemodeSandbox` 直接在调用线程运行，适合能接受阻塞的宿主。portable 入口不包含 Node imports，方便这些环境共用同一脚本 API。

11.3 Durable 恢复的是执行历史，不是 VM 内存快照

`pi-durable` 在 v0.99.2 的仓库中已经存在，最新区间新增的是与确定性脚本重放结合的 Code Mode 等能力。它是实验 API，版本间可随时变化。Harness 把会话条目、文档状态、任务和提交放进存储，提交后才发布相关状态；持久任务保存阶段检查点，重启后继续调度。S23



Durable Code Mode 的记录、重放与继续

运行脚本时：

1. 固定虚拟时钟、随机种子、时区和 VM 指纹等条件。
2. 脚本发出嵌套工具调用，工具本身成为 Durable 任务。
3. 宿主在把结果交给 VM 之前，将结果与顺序写入 journal。
4. 进程崩溃后重新运行脚本，按原来顺序喂入记录的结果。
5. 脚本因此发出相同调用，按 key 重新关联已完成或仍在运行的任务，再继续新的工作。

`sandbox.start()` 的确定性约束包括：`Date.now()` 来自宿主提供的时间、随机性来自 seed、固定 UTC、不暴露 WeakRef/FinalizationRegistry、结果按宿主编号应用。它不要求保存整个 QuickJS 堆快照。S13、S23

一个“扣款后崩溃”的边界案例

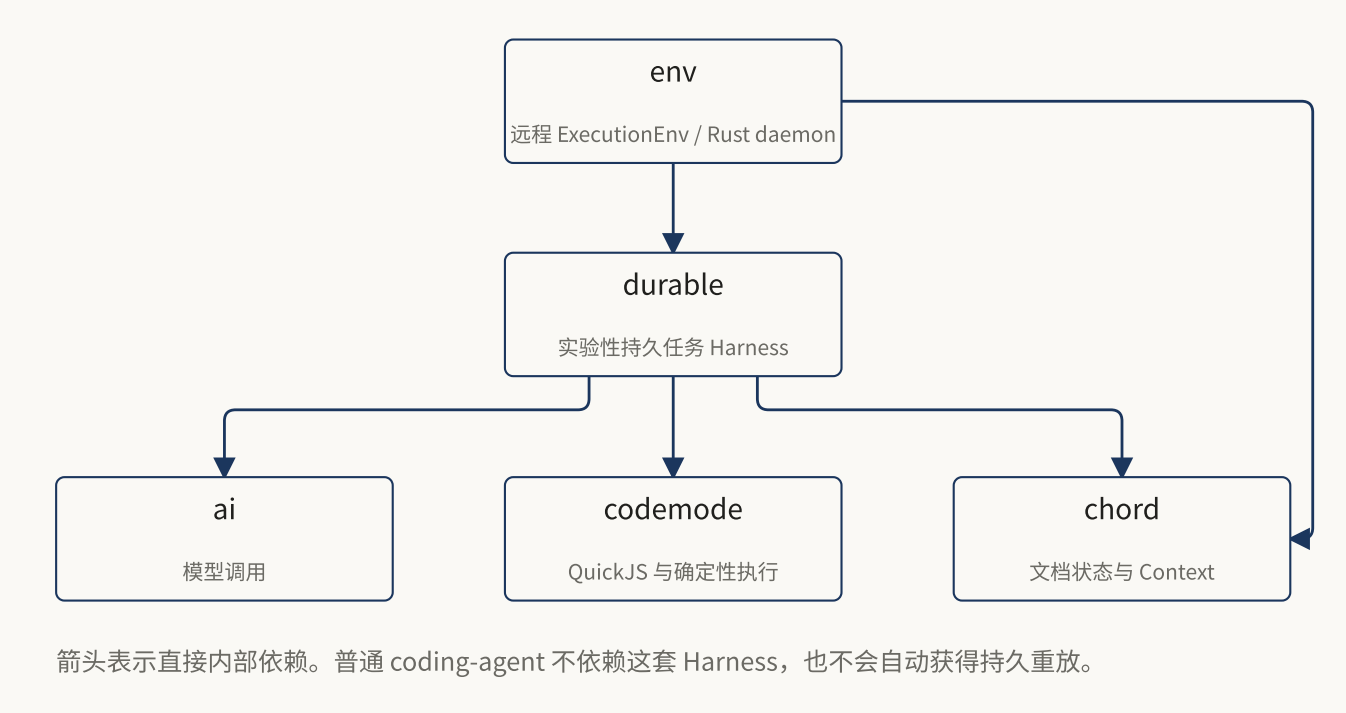
假设工具向外部系统发起一笔扣款，外部扣款成功，但本地还没记录结果就崩溃。重启后能否再次调用？这不能靠“脚本可以重放”来决定。Durable 工具只有声明 `replay: "safe"` 才能在中断后重新执行，否则会产生 interrupted 错误。即便声明了 safe，外部副作用仍需服务端幂等 key 或查询确认。S23

所以它并不提供跨任意外部服务的“恰好一次副作用”魔法。它提供的是可记录、可检查、可恢复的调度和调用关系。代码路径改变、VM 指纹或 Code Mode 版本变化，以及 deadline 已经过期，都可能令重放报错，而不是盲目继续。

11.4 远程执行环境解决另一个问题

`pi-env` 把 Durable 工具的文件与命令操作转到远端机器：本地保留 Harness、存储和凭据；通过 SSH 启动小型 Rust daemon，运行协议化文件与进程操作。`RemoteExecutionEnv` 尽量保持与 `NodeExecutionEnv` 相同的语义。S24

这与把 QuickJS VM 放到远端是两个独立选择：VM 放在哪里，决定脚本计算在哪里；执行环境放在哪里，决定文件和命令在哪里发生。远程执行也不会自动成为沙箱，仍需限制远端账户权限、网络和可用凭据，并核验 SSH host key。



Durable、Code Mode、模型层与远程执行环境的实际包关系

这张图应与第 3 章的 CLI 依赖图分开阅读：一个是实验性持久执行方案，一个是普通编码代理。两者复用模型和沙箱基础库，不意味着生命周期、状态格式和恢复契约相同。

第 12 章：迁移路线与动手实验

本章目标：把概念变成能检查的操作，不在读完后只记得名词。

12.1 从 v0.9.4 迁移，先选你实际使用的层

如果只是使用终端 CLI，备份会话与配置、确认新包名和运行环境，再逐步开启功能。当前 README 要求 Node.js 22.19 或更新；不要把旧仓库根目录的 Node 20 要求当作现版本要求。

如果嵌入的是旧 `Agent`，重点检查 transport API 到当前 `streamFn` / 消息转换接口的变化、旧附件模型、事件与并发语义。不要只替换 npm 包名就假定类型兼容。若依赖旧 `AgentHarness`，当前 `pi-agent-core` 已不再导出它，需要明确迁向 `AgentSession` 还是实验性 Durable。S6、S22

如果自定义过 hooks 与 tools，按当前 extension API 合并注册位置，并按事件的准确返回类型处理阻止、变换与通知。不要只把早年事件名机械替换成新名字而不检查契约。

12.2 从 v0.99.2 迁移，做一张小检查表

- [ ] 识别工具存在性用 `"name" in tools`，不靠读取未知成员。
- [ ] 发现 helper 全部有 `await`。
- [ ] shell 判断退出码，MCP 判断 `isError`。
- [ ] options 行确实在脚本第一行。
- [ ] 需要保存的图片调用 `image()`，不把 base64 当文本输出。
- [ ] 自定义沙箱资源池按真实 worker 退出释放容量，排队不重置总 deadline。
- [ ] `reserveTokens` 按触发阈值配置，不继续当摘要输出帽子。
- [ ] 图片分类核对 `input`、provider 图片协议、错误结果与 usage。
- [ ] 自定义编排器声明正确的 `reachesTools`。
- [ ] 旧 experimental harness 或 server/client 导出没有继续被引用。
- [ ] 恢复会话后验证活动工具与过滤策略，不仅看启动命令。
- [ ] SDK 明确添加需要的内置扩展并绑定生命周期。

12.3 在不改安装的情况下阅读本次下载

以下命令核对本机保留的研究副本；公开电子书不附完整 Git 目录。其他读者可先下载本版源码 ZIP，或按固定标签准备自己的副本。

```
# 在电子书仓库根目录执行。

git -C sources/pi-v1.4.0 describe --tags --exact-match
# v1.4.0

# 上一版参照仍保留：
git -C sources/pi-mono describe --tags --exact-match
# v1.3.0

git -C sources/pi-v0.9.4 describe --tags --exact-match
# v0.9.4

git -C sources/pi-v0.99.2 describe --tags --exact-match
# v0.99.2
```

`pi-mono-v1.4.0.zip` 是不包含依赖与 Git 历史的源码快照，方便离线拷贝。安装依赖或更新全局 Pi 是独立操作，本次没有执行。

实验 A：开启 Code Mode，但保留默认工具

在确认安装版本支持这些参数后，可运行：

```
pi --tools +codemode
```

或将下面字段合并到项目 `.pi/settings.json`，不要直接覆盖已有文件：

```
{
  "defaultTools": ["+codemode"]
}
```

请模型读取几个小文件并只返回选中字段，观察一个外层 Code Mode 调用和多个嵌套调用。对比要求它把每个完整文件都输出时的结果大小。这里测试的是信息选择，不是证明任何固定 token 节省比例。

实验 B：不用模型，测试相同脚本的控制流

本书提供 `examples/run-checks.mjs`，使用 Node 内置断言和模拟工具运行脚本文件：

```
node examples/run-checks.mjs
```

它检查并行读取与字段筛选、部分失败保留、非零 shell 退出码、成功/失败状态提交、图片分类的成功与失败契约，以及输出减量算术。它不是 QuickJS 的安全测试，不调用外部服务，也不能证明 MCP 或真实沙箱没有缺陷。Code Mode 脚本放在 `examples/scripts/`，可以阅读，也可以交给 Pi 使用。

实验 C：观察分支与外部世界的区别

在临时项目里执行一个脚本，保存小游标并写入测试文件。回到保存前的会话节点创建另一分支，再 `load()`：游标沿新分支重建，但文件不会因此恢复。只使用可丢弃文件，不要拿生产数据做这个实验。

实验 D：按官方 SDK 示例接上 MCP

`examples/sdk-codemode-mcp.ts` 是固定版本官方示例的副本。重点阅读三处：`extensionFactories` 安装三个内置扩展；`defaultTools` 增量启用；`session.bindExtensions({})` 发出启动事件。真正运行还需要当前包、凭据和 MCP 配置。本次没有自动执行付费模型调用，也没有添加服务器。

五个问题，检查是否真的理解

1. Code Mode 是否等于多个工具并行？ 不等于。新版普通调用也能并行；Code Mode 多了程序控制流和中间结果筛选。
2. 脚本失败，之前写文件会撤销吗？ 不会。成功才提交的小 store 与外部文件写入没有统一事务。
3. MCP Promise fulfilled 是否意味着成功？ 不意味着。还要检查 `isError`。
4. 普通 CLI 恢复会话是否会从脚本中断的语句继续？ 没有这个通用保证。Durable Code Mode 通过日志和确定性重放提供另一种恢复机制。
5. QuickJS 没有文件系统，shell 就安全吗？ 不能这样推断。注入工具背后的权限才决定影响范围。

常用词，放回各自的位置

词	在本书中的含义
Agent loop	模型响应、工具执行、下一轮判断的循环
Harness	循环外围的上下文、状态、资源和生命周期设施
AgentSession	普通编码代理中拥有会话及运行状态的对象
Turn	一次模型响应及其工具调用
Run	一次输入引发的一个或多个回合及收尾
Exposure	工具如何被模型看见、如何被其他工具调用
Loadout	当前声明和可调用工具的配置视图
Nested call	由工具内部发起、结果先返回调用者的调用
Projection	从持久历史构建出的模型可见上下文
QuickJS / WASM	JavaScript 引擎及其在沙箱中的运行载体
Journal / replay	记录已交付结果，再按确定顺序重放
Idempotency	重试同一业务操作不重复产生不可接受副作用的契约

接下来沿源码读哪几处

从普通 CLI 入手，先读 `how-pi-works.md` 和 `sdk.md`，再读 Code Mode 文档、`tool.ts` 与 `execute.ts`。想把脚本能力放进自己的产品，优先读独立 `codemode/README.md`。只有确实需要跨重启任务恢复，再进入 Durable 的 README 和规范，不要一开始就把实验 runtime 当作必要前置。

所有图都按职责做了适度简化。各模块内部的重试、流式事件和 schema 细节应回到下一节的固定版本来源核对。

来源索引与核查范围

所有文件链接固定到对应版本标签。方括号来源编号可从正文跳转；源码副本位于同目录 `sources/`。

[S1] 最新发布与固定标签

本版正式发布端点：v1.4.0，2026-10-21；详细元数据见 versions.json。

[S2] coding-agent 版本变更日志

版本时间线、Code Mode/MCP 引入、1.0 至 1.4 的功能与修复。

[S3] 旧版有状态 Agent

transport.run、消息转换、事件与队列。

[S4] 旧版 ai 包中的工具循环

校验、顺序工具执行、回合循环。

[S5] 旧版线性 SessionManager

JSONL 记录与复制到新文件的分支方式。

[S6] 当前 Agent 核心文档

消息变换、事件、并行默认执行及顺序保证。

[S7] How Pi Works

当前主运行链、上下文、会话和接口。

[S8] 普通 CLI 包清单与依赖

依赖精确固定；不依赖 pi-durable、pi-env 或 chord。其他包的 package.json 同保存在下载源码中。

[S9] SDK 生命周期与状态

AgentSession、SessionManager、agent_settled、资源加载与内置扩展差异。

[S10] Code Mode 用户与脚本契约

全局接口、返回值、输出、store、models 与限制。

[S11] 当前会话文件格式

树形条目、压缩、context_edit、自定义状态、上下文投影。

[S12] 压缩机制

阈值、保留边界、摘要、分支总结与恢复。

[S13] 独立 Code Mode 沙箱库

worker 与 QuickJS、独立使用、Cloudflare、确定性 start 和结果契约。

[S14] Code Mode executor 实现

ctx.executeTool 调用链、结果适配、状态提交、worker 数量控制。

[S15] 扩展、嵌套调用与工具契约

exposure、prepareLoadout、reachesTools、状态、事件与权限扩展。

[S16] MCP 接入与 exposure

命名、连接时机、发现、过滤、完整 MCP 返回对象、OAuth 与替换扩展。

[S17] 设置与工具呈现

defaultTools、codemode.mode、inlineBudget、TUI 与会话设置。

[S18] 删除未发布的实验服务栈

2026-10-12：客户端、协议、服务端实验栈清理；不等于正式 CLI 换内核。

[S19] 命令行参考

启用 Code Mode、增量工具选择、MCP 排除、运行模式。

[S20] 官方 SDK Code Mode/MCP 示例

添加三个内置扩展、启用工具、bindExtensions、释放资源。

[S21] 独立 Code Mode 包的版本变化

start、portable、remote、未知成员、冻结内建对象、close 与 worker 生命周期。

[S22] Agent 包迁移与清理记录

旧 transport 删除、并行工具执行、1.0.0 移除实验 harness 导出。

[S23] 实验性 Durable Harness

任务与存储、Code Mode journal/replay、幂等与 replay 策略、独立 API。

[S24] 远程执行环境 pi-env

SSH、Rust daemon、RemoteExecutionEnv、host key 与远程语义。

[S25] 安全与项目可信决策

无默认逐调用审批；OS 权限、容器、可信资源与 prompt injection 边界。

[S26] v1.4.0 worker 排队与容量准入

reserveCodemodeWorker、FIFO 放行、60 秒等待、总 deadline 与 PI_CODEMODE_MAX_WORKERS。

[S27] v1.4.0 分类器图片能力与供应商边界

input 能力、图片格式、System One 接入差异、usage 与费用。

[S28] v1.4.0 摘要输出预算实现

移除固定输出比例帽子，保留旧函数参数位置，将自定义指令传入回合前缀摘要。

[S29] v1.4.0 Models Configuration 字段参考

从 schema 生成的 provider、模型和兼容字段，含分类器图片协议选项。

核查范围与限制

本书对照官方发布 API、四个固定标签、相关包清单、主运行链文档、核心循环及 Code Mode 适配实现，保存了完整 diff 清单。书中代码区分可运行示例与占位伪代码。

教学脚本使用 Node 和模拟工具验证。HTML、PDF、EPUB 另做渲染或结构检查。没有运行完整上游测试套件，没有部署 Cloudflare 或 SSH 环境，没有用付费模型验证生成质量，没有做沙箱安全审计；上游测量数据明确标注为上游结果。

优先深入阅读：S7 建立全景；S10 理解脚本契约；S13 研究独立沙箱和部署；S15 理解嵌套工具与扩展；S23 理解实验性持久执行。

固定提交

- `v0.9.4`：`a484330cd15e5844dfa42a4749594067128ea0c1`
- `v0.99.2`：`005af57d88ee23b33778f343a9595b32e67ff788`
- `v1.3.0`：`71023aec1546d6d677a65669c5665c0927ce0dd0`
- `v1.4.0`：`4a080252f06caf63a525d7873c5d94d3c23887e0`

来源材料为官方仓库中的文档与源码；电子书是整理后的教学解释，不代表项目官方文档。

阅读建议：先运行教学检查，再对照固定版本源码核对你需要迁移的接口。下载的是源码，没有修改当前 Pi 安装。